

DOI:10.3969/j.issn.1007-9580.2024.06.012

开放科学(资源服务)标识码(OSID):



谢小文,袁红春.基于多尺度残差连接的水下图像自适应增强[J].渔业现代化,2024,51(6):115-124.

基于多尺度残差连接的水下图像自适应增强

谢小文,袁红春

(上海海洋大学信息学院,上海 201306)

摘要:为解决水下图像常见的颜色失真、对比度降低以及有监督方法在缺乏大规模成对的高质量水下图像数据集支持时效果一般等问题,提出了一种无监督水下图像增强方法,该方法利用条件变分自动编码器(cVAE)结合概率自适应实例归一化(PAdaIN)以及多色空间拉伸技术,旨在提高生成图像的视觉质量,确保生成图像与原始输入图像在视觉上具有一致性。此外,多尺度残差连接模块有效减少了非关键信息的传递,进一步提升了模型的性能。该方法提供了一个以依赖参考图像作为训练数据的替代方案。结果显示,该方法在测试集上的峰值信噪比(PSNR)和结构相似性指数(SSIM)分别比FunieGAN和Water-Net提升12%和3%,显著改善了增强后图像的视觉效果,同时,该方法在不同测试集上的优异表现也验证了其良好的泛化能力。研究表明,该方法在无需参考图像的情况下,显著改善了水下图像的质量,有效提升了图像的细节和色彩校正,为水产养殖和海洋监测提供了一个有效的解决方案。

关键词:水下图像增强;无监督学习;多尺度残差连接;图像处理;概率模型

中图分类号:TP391.4

文献标志码:A

文章编号:1007-9580(2024)06-0115-010

随着对水下环境研究的深入,渔业领域逐渐认识到水下图像质量对资源评估、捕捞策略及渔场管理的重要性。然而,由于水下环境的复杂性,实际获取的图像常常存在退化现象,包括对比度不足、细节模糊和色彩失真,这些问题影响了水下图像的质量,严重妨碍了对渔业资源的精准观察与分析^[1-2],对水产养殖、渔业监测等实际应用造成了不利影响^[3]。

应用图像增强技术能够有效改善这些缺陷,提升图像的清晰度与可视性,从而支持对水下生物和物理特征(如鱼群分布、栖息地状况及水质变化)的准确识别与分析^[4-5]。传统的水下图像增强方法基于水下图像的物理特性而提出。如基于归一化的方法^[6]、基于Retinex理论的方法^[7]等,这些方法研究了由于颜色偏差或散射造成的退化物理机制,并对其进行补偿以增强水下图像。然而,这些基于物理模型的方法表征能力有限,无法处理水下场景中所有复杂的物理和光学因素,

这导致在高度复杂和多样的水下场景中增强效果不佳。近几年,随着深度学习技术的引入,特别是通过基于卷积神经网络的方法^[8]首次被应用于水下图像增强领域,将模糊和颜色失真的图像转化为清晰度更高、色彩更为鲜艳的图像,但仍然存在色偏、对比度低以及噪声较大等问题。Krishnan等^[9]提出了一种利用残差神经网络增强水下图像的方法,有效地将模糊的水下图像转化为清晰的图像。Chen等^[10]提出了一种混合式水下图像增强技术,该方法通过利用雾线先验从退化的水下图像中恢复出清晰的水下图像,引入对比度增强方法来丰富色彩和细节,解决了水下图像对比度低、色偏的问题。Luo等^[11]提出了一种多分支特征融合网络,可以同时恢复和增强水下图像,在保持内容风格和空间纹理的同时提高色彩表现。

Chai等^[12]提出了一种基于物理成像模型的无监督水下图像增强方法,该方法将水下图像分

收稿日期:2024-10-07

基金项目:国家自然科学基金项目“基于海洋大数据深度学习的渔情预测模型研究(41776142)”

作者简介:谢小文(2001—),男,硕士研究生,研究方向:人工智能应用。E-mail:2334540259@qq.com

通信作者:袁红春(1971—),男,教授,研究方向:人工智能应用。E-mail:hcyuan@shou.edu.cn

解为场景辐射度、直接传输图、反向散射传输图和全局背景光 4 个组成部分,通过自监督的方式组合,实现水下图像的重建。Lu 等^[13]提出了一种融合循环生成对抗网络和结构相似性函数的多尺度循环生成网络方法^[14],将图像从浑浊的风格转换成清晰的风格,从而达到了无监督水下图像增强的目的,改善水下图像的质量。

上述方法主要依赖成对的数据集进行训练,通过学习大量数据集,提升了图像的清晰度和色彩表现。然而,这些方法对大规模高质量图像数据集的依赖使得其在实际应用中受到限制^[15],特别是在缺乏参考图像的情况下,增强效果不佳。近年来,学者尝试将无监督学习引入水下图像增强领域,旨在解决上述问题。无监督学习方法不需要大量配对数据集,能够更灵活地处理水下图像的增强任务^[16]。然而,现有的无监督方法在生

成图像的质量上仍存在不足,尤其在色偏纠正和细节还原方面表现不佳。

本研究提出了一种基于多尺度残差块 (Multi-scale Residual Connection Block, MRCB) 的水下图像自适应增强方法,利用无监督学习策略,有效改善了水下图像的对比度和色彩表现,同时提升了细节清晰度,为水产养殖与海洋生态监测提供了可靠的技术支持。

1 研究方法

1.1 网络体系结构

模型主要由参考图像生成模块、多尺度残差连接模块以及概率模块 PAdaIN 构成,分为训练阶段和测试阶段。输入的三维水下图像范围在 0~1 之间,通过 U-Net 提取特征,并利用 PAdaIN 等模块生成增强图像,具体如图 1 所示。

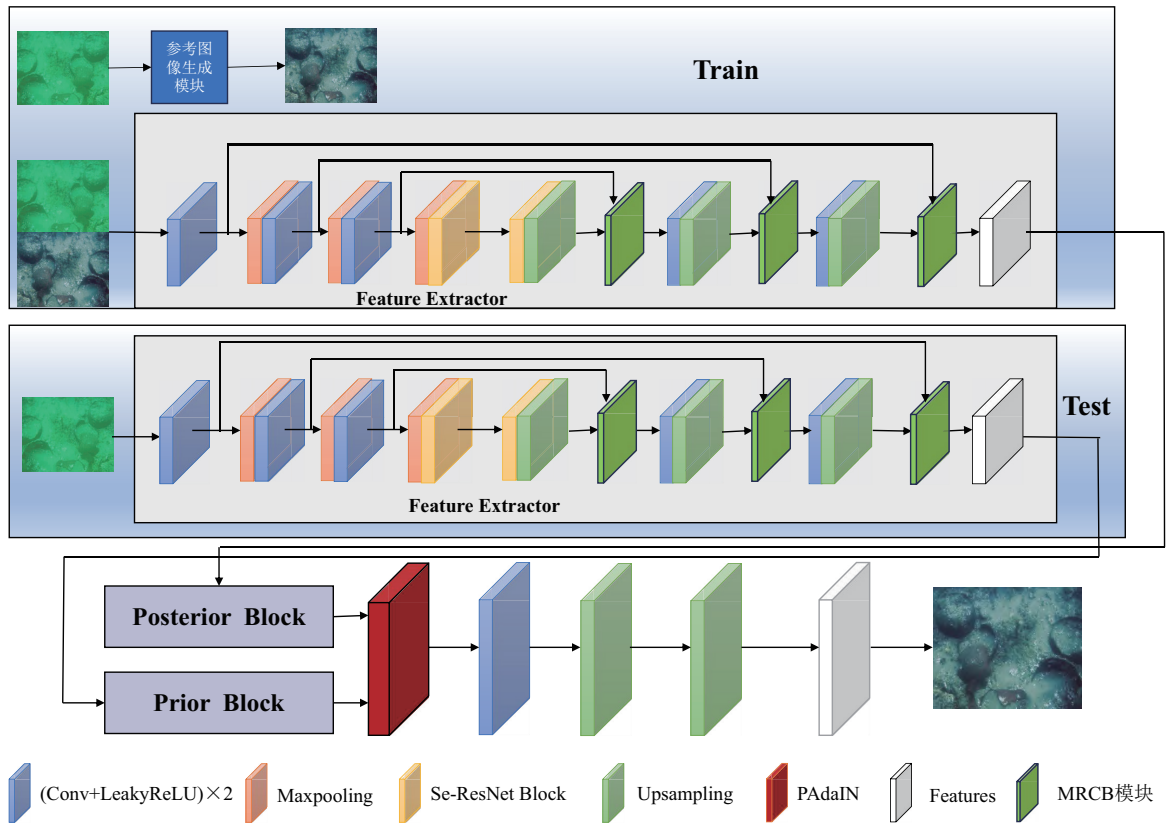


图 1 网络结构图

Fig. 1 Network structure diagram

在训练阶段,首先通过参考图像生成模块创建相应的参考图像,然后对参考图像进行特征提

取处理,得到一系列特征表示。接着,这些特征表示分别输入后验块和先验块进行进一步计算和优

化。最终,这两个块的输出结果被融合,形成完整的模型。

在测试阶段,输入图像同样经过特征提取模块处理,获得对应的特征表示。这些特征表示随后送入后验块和先验块进行计算,最终输出结果被融合,生成增强图像。本研究提出的模型采用分层学习的方法,通过多层次的特征提取和融合,实现了高效的图像处理和增强。同时,参考图像生成模块能够更好地模拟真实场景,提高模型的泛化能力。

1.2 参考图像生成模块

参考图像生成模块主要使用颜色校正的方法来生成参考图像,通过将参考图像 RGB 值转换为最佳 RGB 值来改善生成的参考图像的颜色和对比度,这一过程包括确定适用于色彩中性拍摄对象的相机白平衡,以及去除透镜眩光和红绿色差

的影响。颜色校正方法主要用于已知红色、绿色和蓝色(RGB)平均值和标准偏差的情况,使用非参数方法进行颜色校正^[17],能够实现 RGB 颜色通道中像素值的新统计分布。参考图像生成模块主要由两个部分组成:双统计平衡模块(Dual-statistic White Balance Module)和多色空间拉伸模块(Stretch Module),其结构如图2所示。

为了将不确定性引入数据集,对原始图像进行对比度和饱和度调整以及伽马校正,通过这些变换可以更加有效地模拟水中常见的失真等现象,具体如公式(1)所示:

$$y = (x - m) \times \alpha + x \quad (1)$$

式中: x 和 y 表示退化图像和增强图像, m 表示每个通道的平均值, α 是调整系数,用以创建不确定性标签,用来反映真实图片记录中的不确定性,而不改变原始标签。

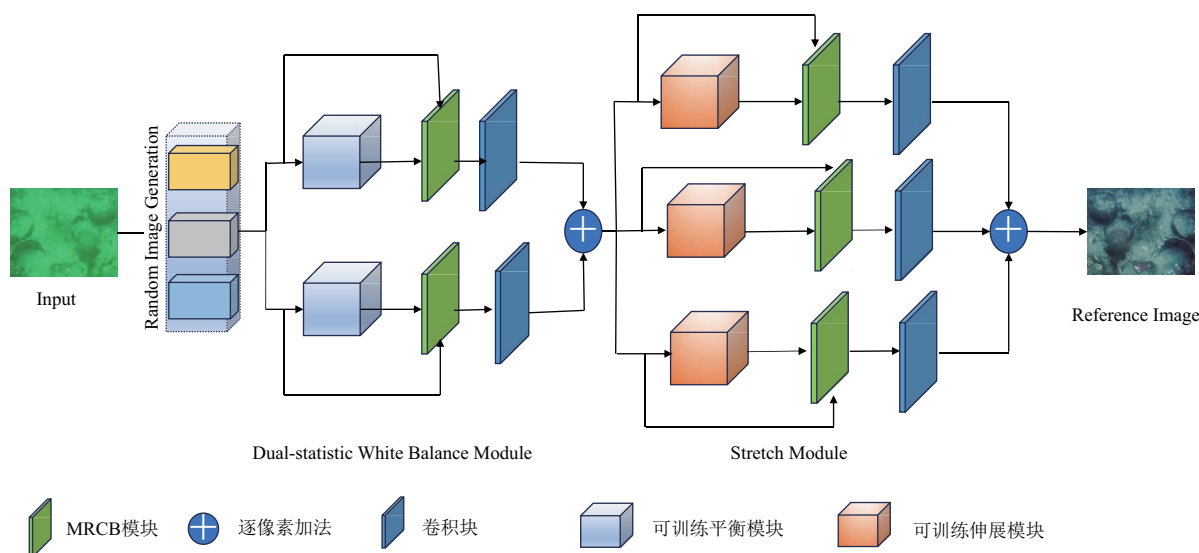


图2 参考图像生成模块

Fig. 2 Reference image generation module

1.2.1 双统计平衡模块

图像由两个不同的模块处理,这两个模块使用图像的统计数据(平均值和最大值)来校正其色彩平衡。然后使用两个残差模块来增强输出以恢复丢失的细节。

首个训练模块采用灰色世界理论,这是一种假设图像中的平均颜色为灰色,即R、G、B通道平均值相等的色彩校正方法,具体如公式(2)所示:

$$x^{GW} = \text{Conv}_{1 \times 1}(x) \otimes \bar{A} \quad (2)$$

式中: $\bar{A} = [\frac{1}{A_R}, \frac{1}{A_G}, \frac{1}{A_B}]$, A_R 、 A_G 、 A_B 分别表示原始图像中R、G、B通道的平均值, \otimes 表示逐像素乘法, x^{GW} 表示基于灰度世界理论的颜色校正结果。

第二个训练模块利用白色补丁算法进行颜色校正,它假设图像中的最高RGB值来源于场景的白色区域,反映光源颜色,据此调整整幅图像的色彩。基于这一假设,每个通道的比例因子如公式

(3)所示:

$$x^{WP} = \text{Conv}_{1 \times 1}(x) \otimes \bar{M} \quad (3)$$

式中: $\bar{M} = [\frac{1}{M_R}, \frac{1}{M_G}, \frac{1}{M_B}]$, M_R 、 M_G 、 M_B 分别表示原始图像中 R、G、B 通道的最大值, x^{WP} 表示基于白色补丁算法的颜色矫正结果。

结果被合并,传递给拉伸模块,具体如公式(4)所示:

$$x^{DSB} = \text{Conv}_{3 \times 3}(x^{GW}) \oplus \text{Conv}_{3 \times 3}(x^{WP}) \quad (4)$$

式中: x^{DSB} 表示由双统计平衡模块增强的结果。

1.2.2 多色空间拉伸模块

图像被转换到不同的颜色空间 (HSI 和 LAB),并由可训练模块处理以提高对比度。原始图像也被增强,具体如公式(5)所示:

$$x^{final} = \text{Conv}_{3 \times 3}(x^r) \oplus \text{Conv}_{3 \times 3}(x^h) \oplus \text{Conv}_{3 \times 3}(x^l) \quad (5)$$

式中: x^r 、 x^h 、 x^l 分别表示 RGB、HSI、Lab 颜色空间中的直方图拉伸像素值, x^{final} 表示由多色空间拉伸模块增强的结果。在 HSI 颜色空间中,色调 (H) 通道保持原样,之后输出转换回 RGB 颜色空间^[18]。这包括 3×3 卷积层处理和像素累加合并结果。通过调整颜色平衡和提高对比度,显著改善了传递至概率模块的参考图像的视觉质量。

1.3 MRCB 模块

在模型的框架中,为了更好地获取上下文信息,改善网络的特征表达能力,提出了一种全新的多尺度残差连接模块 (MRCB)。MRCB 可以抑制噪声和不重要的特征传递,仅允许输入数据的重要特征进一步传递,从而提升模型的性能,其示意图如图 3 所示。MRCB 的总体流程如公式(6)所示:

$$F_{MRCB} = F_{input} + GCA(F_{input}) \quad (6)$$

式中: F_{input} 代表原始输入特征, GCA 代表全局上下文注意, GCA 由 3 个部分实现:

(1)上下文建模:首先从原始特征图 F_{input} 通过重构操作以生成特征 F_1 。接着, F_{input} 经过一系列的卷积、重构和 Softmax 操作,生成新的特征 F_2 ,然后对 F_1 和 F_2 进行逐像素乘法,生成全局特征描述符 F_3 。

(2)通道交互:为了获取不同通道间的相关性,将 F_3 进行特征变换,使用两个 1×1 卷积和一个 LeakyReLU 激活函数,生成新的注意力特征 F_4 。

(3)特征融合:采用逐元素加法将特征 F_4 融合到原始特征 F_{input} 的各个位置,旨在降低过拟合风险并增强特征的多样性。

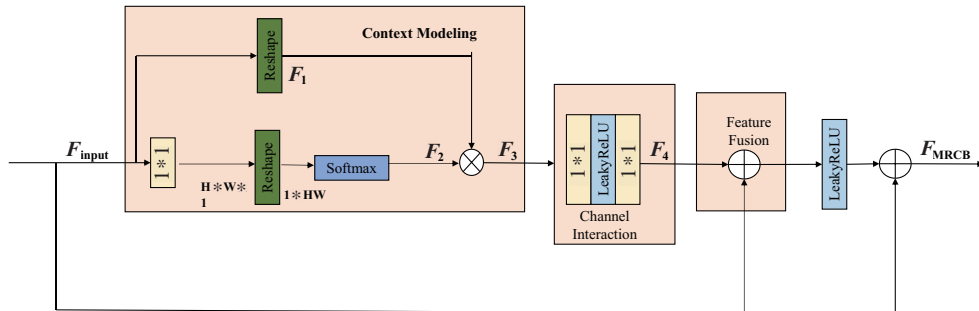


图 3 多尺度残差连接模块结构图

Fig. 3 Structural diagram of the multi-scale residual connection module

1.4 概率模块

本研究的核心思想是在水下图像增强过程中引入不确定性。由于在实际应用中,获取真实和清晰的图像存在困难,且训练模型使用的标签也可能带有不确定性。为解决这一问题,本研究基于 AdaIN 算法^[19]设计了概率模块 (PAdaIN),该模块主要用于图像风格转换,通过调整图像特征

的均值和标准差来匹配样式,改变图像的外观,保留其内容特性。

然而,AdaIN 依赖于已知内容和样式图像的可用性,为了解决这个问题,PAdaIN 引入了来自均值和标准差的后验分布的随机样本作为 AdaIN 的参数,具体如公式(7)所示:

$$PAdaIN(x) = b \left(\frac{x - \mu(x)}{\sigma(x)} \right) + a \quad (7)$$

式中: b 和 a 分别是来自均值和标准差的后验分布的两个随机样本, $\mu(x)$ 表示输入特征 x 的均值, $\sigma(x)$ 表示输入特征 x 的标准差。后验分布和先验分布结构示意图如图4所示。 $PAdaIN$ 能够捕获输入图像的重要外观相关特征,并使用它们生成增强图像,以保持原始图像的完整性。

通过隐式变量 z 表示增强过程的不确定性,它可以反映个人偏好或捕捉生成实际图像时的相

机及算法参数。模型旨在学习从原始图像 x 到增强图像 y 的映射,同时考虑由 z 变量所代表的不确定性,具体如公式(8)所示:

$$p(y|x) \approx p(y|z_{\max}, x), z_{\max} \sim p(z|x) \quad (8)$$

式中: $p(y|z_{\max}, x)$ 是给定具有最大概率 z_{\max} 和原始图像 x 到增强图像 y 的概率。 $p(z|x)$ 是给定观测值的不确定性变量的概率。该模型的目标是从训练数据中学习这些概率分布,然后使用它们来生成增强图像,将不确定性纳入增强过程。




图4 后验分布和先验分布结构图

Fig. 4 Structure diagram of posterior and prior distributions

1.5 损失函数

均方误差损失 L_{mse} 和感知损失 L_{vgg16} 是评价图像增强算法性能的两个常用指标,均方误差损失测量预测图像和参考图像之间的平均平方差,感知损失^[20]测量预测图像和参考图像的高级特征之间的差异。权重 λ 用于控制这两个损失项在总体增强损失 L_e 中的相对重要性^[21],在训练过程中使用的 λ 的具体值将取决于数据集的特征和模型的期望性能,具体如公式(9)所示:

$$L_e = L_{mse} + \lambda L_{vgg16} \quad (9)$$

除了使增强损失 L_e 最小化之外,模型的训练过程还涉及使用 KullbackLeibler(KL) 发散 D_{KL} 来将后验分布与先验分布对齐。KL 散度是两个概率分布之间差异的度量,可用于比较模型学习的后验分布与假设代表训练数据中潜变量分布的先验分布。通过最小化后验分布和先验分布之间的 KL 偏差,该模型能够学习潜在空间的更准确表示,以提高增强图像的质量。KullbackLeibler(KL) 具体如公式(10)和公式(11)所示:

$$L_m = D_{KL}(M_m(x) || M_m(y, x)) \quad (10)$$

$$L_s = D_{KL}(M_s(x) || M_s(y, x)) \quad (11)$$

式中: L_m 和 L_s 分别为平均值和标准差。 $M_m(x)$ 和

$M_s(x)$ 分别表示 x 输入特征的均值 m 和标准差 s 的正态分布。

用于训练本研究模型的总损失函数是后验分布和先验分布之间的增强损失 L_e 和 KL 偏差 D_{KL} 的加权和,具体如公式(12)所示:

$$L = L_e + \beta(L_m + L_s) \quad (12)$$

式中: β 为权重,值为 0.5。

2 结果与讨论

2.1 试验准备

数据集:1) EUVP^[22] 数据集,选取 3 700 对成对的图像,其中每张水下图像均包含对应的参考图像,作为训练集一;2) UIEBD^[23] 数据集,选取 5 000 张原始水下图像,原始水下图像没有与之对应的参考图像,作为训练集二;3) UFO-120^[24] 数据集选取 300 张严重失真的水下图像作为测试集一;4) 利用 PowerVision 水下无人机在学校教学楼外池塘拍摄了一组真实水下图像数据集,从中挑选了 100 张图片作为测试集二。分别用训练集一和训练集二对模型进行训练得到模型一和模型二。

本模型的实现基于 PyTorch 深度学习框架,

采用的显卡为 NVIDIA 的 GeForce RTX3090 (24 GB)。在训练时输入 256×256 的图像,初始学习率设置为 0.000 1,批量大小为 8,采用的优化器是 Adam^[25],迭代次数为 300 次。模型采用无监督学习方式,采用颜色矫正的方法生成参考图像,并利用生成的参考图像训练模型,通过对齐先验分布和后验分布以确保生成的图像更加准确,且通过 MRCB 模块可以抑制不重要的信息,有效传递重要特征信息,避免梯度消失的问题。

评价指标:全参考评估指标包括峰值信噪比 (PSNR)、结构相似性 (SSIM)、学习感知图像块相似度 (LPIPS)。无参考评估指标为:水下图像质量测量 (UIQM)、水下彩色图像质量评估 (UCIQE)、自然图像质量评估 (NIQE)、水下图像对比度测量指标 (UICM) 和水下图像锐度测量指标 (UISM)^[26]。

2.2 对比试验

2.2.1 定量比较

为了比较提出的算法性能,选择了 5 种传统的无监督学习方法:CLAHE^[27]、HE^[28]、UDCP^[29]、RGHS^[30]、UCM^[31],以及 4 种基于深度学习的方法:UGAN^[32]、Water-Net^[33]、UWCNN^[34]、FunieGAN^[35],总共 9 种方法与本研究方法比较。与传统的无监督方法进行比较,可以体现本研究提出的无监督方法的优势。表 1 表示本研究选取的 11 种模型在测试集一上的试验结果,测试集一使用有参考图像的数据集,采用的是全参考评价指标:峰值信噪比 (PSNR)、结构相似性 (SSIM)、学习感知图像块相似度 (LPIPS) 和水下彩色图像质量评估 (UCIQE)。从表 1 中可以看出:本研究所提出的模型在大多数情况指标值高于所比较的方法,只有 UCIQE 指标逊色一些,没有达到最优和次优,不过也优于其他大多数方法,表明本模型能够有效提升生成图像的质量,能够较好地恢复水下图像的真实色彩。

表 2 表示本研究选取的 11 种模型在测试集二上的试验数据,测试集二使用的是作者拍摄的数据,没有参考图像作为参考,采用的是无参考评价指标:水下图像质量测量 (UIQM)、自然图像质量评估 (NIQE)、水下图像对比度测量指标 (UICM) 和水下图像锐度测量指标 (UISM)。从表 2 中可以看出,本研究提出的模型只有 UIQM 指

标上没有取得最好结果,在其余 3 个指标上均取得最好的结果。

表 1 不同方法在测试集一上的定量对比

Tab. 1 Quantitative comparison of different methods on test set one

方法	PSNR	SSIM	LPIPS	UCIQE
CLAHE	15.886	0.551	0.457	0.465
UCM	17.821	0.768	0.316	0.471
RGHS	18.759	0.787	0.296	0.507
HE	14.219	0.694	0.369	0.492
UGAN	15.228	0.676	0.453	0.429
UWCNN	18.435	0.808	0.354	0.416
UDCP	15.553	0.643	0.313	0.539
FunieGAN	21.667	0.810	0.241	0.418
Water-Net	19.889	0.830	0.177	0.426
模型一	24.171	0.853	0.121	0.473
模型二	24.211	0.849	0.132	0.478

表 2 不同方法在测试集二上的定量对比

Tab. 2 Quantitative comparison of different methods on test set two

方法	UICM	UISM	NIQE	UIQM
CLAHE	14.386	0.368	4.876	1.294
UCM	9.457	0.219	4.424	1.089
RGHS	15.018	0.212	4.472	1.241
HE	15.392	0.339	3.500	1.297
UGAN	10.864	0.120	5.878	1.229
UWCNN	14.607	0.099	3.364	1.174
UDCP	9.802	0.337	3.811	1.369
FunieGAN	12.782	0.198	4.332	1.725
Water-Net	12.853	0.139	5.301	1.439
模型一	15.955	0.525	2.316	1.229
模型二	16.125	0.597	2.507	1.215

2.2.2 定性比较

在水下图像增强,特别是水下彩色图像增强中,人眼视觉感受是非常重要的评价角度。分别选取成对的数据集与作者拍摄的非成对数据集作为测试集进行比较,可以有效地证明本研究的方法在无参考图像环境下的有效性和适用性。

图 5 展示了 11 种模型在测试集一上的增强图片效果。主观分析得出:HE 和 CLAHE 模型生成的图像过亮,未去除绿色,出现曝光问题。RGHS 和 UGAN 处理的图像仍偏绿,不过亮度有所提高。UGAN 使图像更绿,可视度未明显改善,整体效果不佳。UCM、UWCNN、UDCP 处理的图像偏红;UCM 在细节恢复上未达预期,出现颜色

失真;UWCNN 图像过暗,雾化现象没有得到改善,清晰度不足;UDCP 图像也偏暗,视觉效果差。Water-Net 和 FunieGAN 改善了上述问题,但图像

仍偏暗。相比之下,本方法在色彩、对比度、视觉效果及清晰度上都显著优于其他模型,更接近参考图像。




图5 各种模型在测试集一上的视觉质量对比

Fig. 5 Comparison of the visual quality of various models on test set one

图6表示本研究选择的11种模型在测试集二上运行得到的增强后图片。对比图片,模型的优劣可以更好地观测出来。经过HE和Water-Net以及FunieGAN模型处理后的图片,整体偏红,经过FunieGAN模型处理后,整张图片色调完全偏红,其余两个模型处理后的图像出现了严重的图像失真现象。图像经过RGHS和UCM模型增强后,虽然去掉了图像表面的雾,不过整体颜色偏深蓝色,无法还原鱼本身的颜色。经过UGAN

和UWCNN模型处理后的图像,整体色调偏黄,背景也基本上呈现出黄色。CLAHE模型处理后的图像整体颜色偏淡,且图像模糊。UDCP模型处理后的图像,出现了严重图像失真现象,无法准确恢复鱼本身的形状。相比之下,本研究提出的方法,无论采用哪种数据集进行测试,都首先解决了水下图像雾化的现象,其次提高了图片的清晰度,细节处理方面更加优秀。

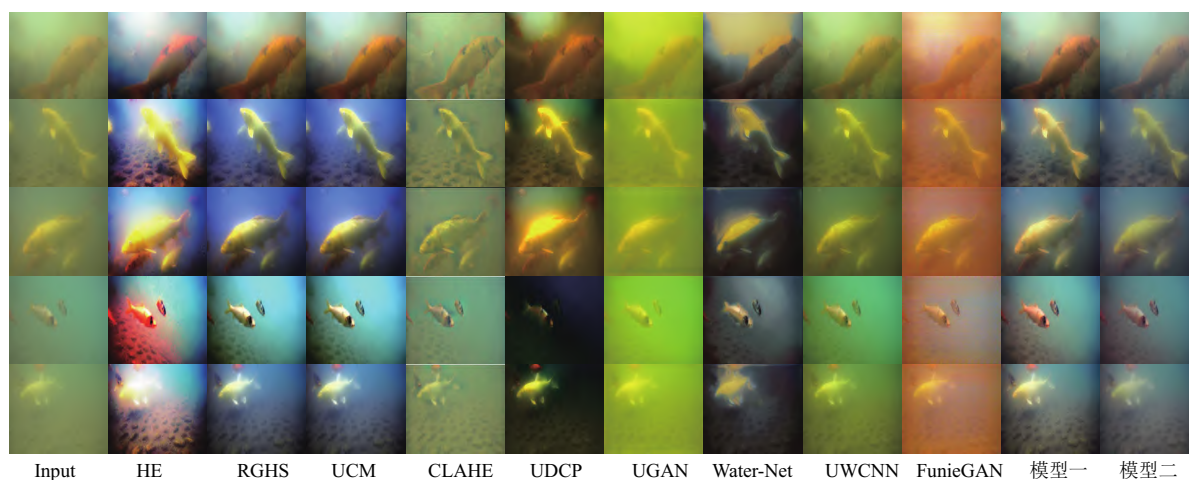


图6 各种模型在测试集二上的视觉质量对比

Fig. 6 Comparison of the visual quality of various models on test set two

2.3 消融试验

为了验证本研究提出模型中模块的有效性,设计了如下消融试验:1)去除多尺度残差连接模块(MRCB);2)去掉概率模块(PAdaIN);3)去除多尺度残差连接模块(MRCB)和概率模块(PAdaIN)。两组试验的模型均迭代50次,均采用训练集二进行训练,并在测试集一和测试集二上进行定量分析,基础模型不包含MRCB模块和PAdaIN模块。所进行的消融试验结果如表3和表4所示,可以看出,两个表格中除了UIQM这个指标外,在其余度量指标上,均是同时包含MRCB模块和PAdaIN模块的效果最佳,在大多数的指标上,只包含MRCB或PAdaIN的模型均达到了次优,可以看出,单独包含MRCB模块或单独使用PAdaIN模块并不是最优选择,两者各有不足的地方,只有两者一起使用,才能让模型的效果达到最佳。

表3 测试集一上消融试验数据

Tab. 3 Ablation experimental data on test set one

方法	PSNR	SSIM	LPIPS	UCIQE
Baseline	15.877 5	0.620 8	0.261 4	0.265 9
Baseline + MRCB	18.360 1	0.685 4	0.211 7	0.369 1
Baseline + PAdaIN	17.280 1	0.693 9	0.212 0	0.385 8
Full Model	20.098 9	0.789 4	0.178 4	0.452 3

表4 测试集二上消融试验数据

Tab. 4 Ablation experimental data on test set two

方法	UICM	UISM	NIQE	UIQM
Baseline	11.184 8	0.367 3	6.292 7	0.508 4
Baseline + MRCB	9.457 1	0.437 1	4.423 6	0.338 9
Baseline + PAdaIN	13.415 1	0.440 3	4.736 9	0.332 9
Full Model	14.955 6	0.503 6	3.433 8	0.489 9

表4中的UIQM指标,不包含MRCB模块或PAdaIN模块的模型效果均未达到最佳,可能原因是使用水下摄像机在学校池塘拍摄时,由于水中存在较多的悬浮物,其可以散射和吸收光线,减少光线直接到达摄像头的量^[36],造成图像模糊和对比度降低,导致UIQM的值不高。

3 结论

本研究提出了一种基于多尺度残差的无监督

水下图像增强方法,使用编码器-解码器结构,实现了水下图像的自适应增强。通过多尺度残差连接模块(MRCB)与概率模块(PAdaIN),模型能够在更好地传递边缘和轮廓以及纹理细节等重要信息的同时,抑制噪声、低对比度区域等不重要信息的传递,模型在不依赖参考图像的情况下,显著提升了增强后图像的清晰度、对比度和色彩。结果表明,该方法在PSNR和SSIM等常用图像质量评估指标上,分别达到了24.211和0.853,均优于当前主流的水下图像增强方法,展现出较强的泛化能力和视觉提升效果。未来,将进一步研究提升模型在复杂水下环境中的适应性,同时提高图像细节的还原能力,以适应更多实际应用需求。

□

参考文献

- [1] 胡雨航,赵磊,李恒,等.多特征选择与双向残差融合的无监督水下图像增强[J].电子测量与仪器学报,2023,37(9):190-202.
- [2] 姜群.基于迁移学习的水下图像增强与目标检测研究[D].济南:山东财经大学,2022.
- [3] 彭小红,梁子祥,张军,等.深度学习驱动的水下图像预处理研究进展综述[J].计算机工程与应用,2021,57(13):43-54.
- [4] FABBRI C, ISLAM M J, SATTAR J. Enhancing underwater imagery using generative adversarial networks[C]//2018 IEEE international conference on robotics and automation (ICRA), Brisbane:IEEE,2018:7159-7165.
- [5] 弭永发,迟明善,张强,等.基于颜色校正与改进的CLAHE多尺度融合水下图像增强[J].无线电工程,2024,54(6):1470-1480.
- [6] CHEN W, GU K, LIN W, et al. Reference-free quality assessment of sonar images via contour degradation measurement[J]. IEEE Transactions on Image Processing, 2019, 28(11):5336-5351.
- [7] 刘彦呈,董张伟,朱鹏莅,等.基于特征解耦的无监督水下图像增强[J].电子与信息学报,2022,44(10):3389-3398.
- [8] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE,1998,86(11):2278-2324.
- [9] KRISHNAN H, LAKSHMI A A, ANAMIKA L S, et al. A novel underwater image enhancement technique using ResNet[C]//IEEE Conference on Information & Communication Technology (CICT), Chennai:IEEE,2020,12:1-5.
- [10] CHEN T, SHEN L, FAN Y, et al. Underwater Image Enhancement Based on Improved Haze-lines Prior and Histogram Distribution Prior[C]//IEEE International Conference on Intelligent Autonomous Systems (ICoIAS), Dalian:IEEE,2022:

- 60-65.
- [11] LUO H, ZHANG G, ZHANG X. MBFFNet: Multi-branch feature fusion network for underwater image restoration [C]// IEEE Information Technology, Networking, Electronic and Automation Control Conference (ITNEC), Chongqing: IEEE, 2023:1209-1213.
- [12] 孙昊宇,牛宏侠. 基于色彩均衡和多权重融合的水下图像增强算法[J]. 无线电工程,2024,54(2):436-446.
- [13] 王德兴,黄梓阳,袁红春. 基于轻量级神经网络的水下生物图像增强[J]. 渔业现代化,2023,50(6):60-73.
- [14] LIU Y, WANG X, WANG L, et al. A modified leaky ReLU scheme (MLRS) for topology optimization with multiple materials[J]. Applied Mathematics and Computation, 2019, 352:188-204.
- [15] 马爱明. 水下复杂环境的图像复原技术研究[D]. 成都:电子科技大学,2023.
- [16] 刘敏. 基于域自适应的水下图像增强[D]. 哈尔滨:哈尔滨工业大学,2022.
- [17] LI C, ANWAR S, PORIKLI F. Underwater scene prior inspired deep underwater image and video enhancement [J]. Pattern Recognition, 2020, 98:107038.
- [18] LI C, ANWAR S, HOU J, et al. Underwater image enhancement via medium transmission-guided multi-color space embedding [J]. IEEE Transactions on Image Processing, 2021, 30: 4985-5000.
- [19] FU Z, WANG W, HUANG Y, et al. Uncertainty inspired underwater image enhancement [C]//Tel Aviv: European conference on computer vision. Cham: Springer Nature Switzerland, 2022:465-482.
- [20] JOHNSON J, ALAHI A, FEI-FEI L. Perceptual losses for real-time style transfer and super-resolution [C]// European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, Amsterdam: ECCV, 2016:694-711.
- [21] 赵兴运,孙帮勇. 融合注意力机制和上下文信息的微光图像增强[J]. 中国图象图形学报,2022,27(5):1565-1576.
- [22] ISLAM M J, XIA Y, SATTAR J. Fast underwater image enhancement for improved visual perception[J]. IEEE Robotics and Automation Letters, 2020, 5(2):3227-3234.
- [23] 丛润民,张禹墨,张晨,等. 深度学习驱动的水下图像增强与复原研究进展[J]. 信号处理,2020,36(9):1377-1389.
- [24] PANETTA K, GAO C, AGAIAN S. Human-visual-system-inspired underwater image quality measures[J]. IEEE Journal of Oceanic Engineering, 2015, 41(3):541-551.
- [25] ZHANG Z. Improved adam optimizer for deep neural networks [C]// IEEE ACM 26th international symposium on quality of service (IWQoS), Banff: IEEE, 2018, 6:1-2.
- [26] 李大海,王忠华,王振东. 结合空间域和频域信息的双分支低光照图像增强网络[J]. 计算机应用, 2024, 44(7): 2175-2182.
- [27] REZA A M. Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement[J]. Journal of VLSI signal processing systems for signal, image and video technology, 2004, 38:35-44.
- [28] LI C, GUO C, REN W, et al. An underwater image enhancement benchmark dataset and beyond [J]. IEEE transactions on image processing, 2019, 29:4376-4389.
- [29] DREWS P, NASCIMENTO E, MORAES F, et al. Transmission estimation in underwater single images [C]//IEEE Proceedings of the IEEE international conference on computer vision workshops, Sydney: IEEE, 2013, 12:825-830.
- [30] HUANG D, WANG Y, SONG W, et al. Shallow-water image enhancement using relative global histogram stretching based on adaptive parameter acquisition [C]// International Conference, MMM 2018, Bangkok, Thailand, February 5-7, 2018, Proceedings, Part I 24. Bangkok: Springer International Publishing, MMM, 2018:453-465.
- [31] IQBAL K, ODETAYO M, JAMES A, et al. Enhancing the low quality images using unsupervised colour correction method [C]// IEEE International Conference on Systems, Man and Cybernetics, Istanbul: IEEE, 2010, 10:1703-1709.
- [32] FABBRI C, ISLAM M J, SATTAR J. Enhancing underwater imagery using generative adversarial networks [C]//Brisbane: IEEE international conference on robotics and automation (ICRA), IEEE, 2018:7159-7165.
- [33] 袁国铭,刘海军,李晓丽,等. 纹理感知联合颜色直方图特征的水下图像增强[J]. 光学精密工程, 2024, 32(13): 2112-2127.
- [34] LI C, ANWAR S, PORIKLI F. Underwater scene prior inspired deep underwater image and video enhancement [J]. Pattern Recognition, 2020, 98:107038.
- [35] ISLAM M J, XIA Y, SATTAR J. Fast underwater image enhancement for improved visual perception[J]. IEEE Robotics and Automation Letters, 2020, 5(2):3227-3234.
- [36] 袁红春,赵华龙,高凯. 基于多阶段协同处理的水下图像增强[J]. 激光与光电子学进展, 2024, 61(8):363-371.

An adaptive enhancement method for underwater images based on multi-scale residual connection

XIE Xiaowen, YUAN Hongchun

(School of Information Shanghai Ocean University Shanghai 201306, China)

Abstract: To address common issues in underwater images, such as color distortion and reduced contrast, as well as the limitations of supervised methods that rely on large-scale paired high-quality underwater image datasets, an unsupervised underwater image enhancement method is proposed. This method utilizes a conditional variational autoencoder (cVAE) combined with probabilistic adaptive instance normalization (PAdaIN) and multi-color space stretching techniques to improve the visual quality of generated images while ensuring consistency with the original input images. Furthermore, a multi-scale residual connection module is employed to effectively reduce the transmission of non-essential information, thereby enhancing the model's performance. This approach provides an alternative to traditional training methods that rely on reference images. Experimental results demonstrate that this method achieves a 12% and 3% improvement in Peak Signal-to-Noise Ratio (PSNR) and Structural Similarity Index (SSIM) on the test set compared to FunieGAN and Water-Net, respectively, significantly enhancing the visual quality of the improved images. Moreover, the method performs excellently across different test sets, demonstrating its robust generalization capability. The study indicates that, without the need for reference images, this approach significantly improves underwater image quality, effectively enhancing image detail and color correction, and provides a viable solution for aquaculture and marine monitoring applications.

Key words: underwater image enhancement; unsupervised learning; multi-scale residual connections; image processing; probabilistic models